

Estadísticas para el Análisis de Negocios

Lic. Santiago Emiliano Eguren, MBA

Introducción	4
Estadística	5
Probabilidad	5
Variable Aleatoria Discreta y Continúa	8
Modelos de distribución	11
Distribución de Bernoulli	11
Distribución Normal	12
Estadística descriptiva	15
Visualización y exploración de datos	15
Tipos de datos	15
Datos categóricos (o cualitativos) y cuantitativos	16
Datos de corte transversal y de series de tiempo	16
Medidas de estadística descriptiva	17
Distribución de frecuencia	17
Datos discretos	17
Datos continuos	19
Media muestral	22
Mediana muestral	22
Moda muestral	24
Cuantil muestral	25
Varianza muestral	28
Desviación estándar muestral	29
Coeficiente de correlación muestral	30
Muestreo y estimación	31
Cómo seleccionar una muestra (finita-infinita)	31
Distribución de muestreo	32
Tipos de muestreo	33
Teorema del límite central	34
Estimación puntual	34
Estimación por intervalo	36
Inferencia estadística	41
Prueba de hipótesis con poblacional conocida	41
Prueba de hipótesis con poblacional desconocida	47
Indicadores y visualizaciones	48

Título 2

49

Título 3

49

pág. de

2

Introducción

En la industria 4.0 se utilizan una gran cantidad de dispositivos que generan datos en cada momento. Estos datos, bien modelados y presentados, producen un gran aporte en la cadena de valor de la empresa. Para poder aprovechar esa valiosa información es necesario que la empresa implemente sistemas de Análisis de datos.

La **analítica de datos** es todo el conjunto de herramientas que permiten extraer, modelar y presentar los datos para la toma de decisiones de los mandos gerenciales de la empresa. La parte del modelado de datos se hace mediante dos grupos de herramientas: **La estadística** y el **machine learning**. El primero de ellos intenta determinar el modelo matemático exacto que explica el comportamiento de los datos y el segundo busca determinar patrones en los datos.

Dicho de otra forma, las soluciones de la analítica de datos tienen tres objetivos principales:

- Extraer datos del proceso industrial
- Ordenar y filtrar los datos
- modelar y elaborar predicciones

Por último la visualización de la información generada debe ser presentada de la forma más efectiva posible y fácil de interpretar, para la correcta toma de decisiones. En este módulo se abordará en forma práctica, los conocimientos básicos de la estadística y de la visualización de datos. En el siguiente módulo se verán los conceptos principales de machine learning.

Estadística

La palabra estadística se deriva de la palabra latina “Status”, que significa “Estado”. Los primeros usos de la estadística implicó la compilación de datos y gráficas para describir diversos aspectos de un país. Posteriormente la estadística se transformó en una herramienta indispensable para la ciencia.

En épocas pasadas, la obtención de datos y los procesamientos de estos tenían un alto costo, por lo que su uso era muy específico y limitado. Posteriormente con las computadoras, la obtención de datos y el procesamiento de estos se transformó en algo de bajo costo y la estadística **saltó al mundo de las industrias**, dejando de ser exclusiva de la ciencias.

Probabilidad

La **probabilidad** es una medida numérica de la posibilidad de que un evento ocurra. Por tanto, se utiliza como una medida del grado de incertidumbre. Si las probabilidades están disponibles, se puede determinar la posibilidad de ocurrencia de cada evento. Por ejemplo nos podría interesar la probabilidad de que un cliente compre, o la probabilidad de que no pague un crédito, o la probabilidad de que un producto sea defectuoso, etc.

Los valores de probabilidad siempre se asignan en una escala de 0 a 1. Una probabilidad cercana a 0 indica que es poco probable que un evento ocurra, una probabilidad cercana a 1 indica que es casi seguro que un evento se produzca.

En el estudio de la probabilidad, un **experimento** se define como un proceso que genera resultados bien definidos. En cada repetición ocurre uno y sólo uno de los resultados posibles del experimento. El **espacio muestral** (representado por la letra S ú Ω) es el conjunto de todos los resultados del experimento. Un suceso es un **subconjunto** del espacio muestral. Los

sucesos se presentan por una letra imprenta mayúscula (por ejemplo: A)

¿Cómo asignar probabilidades?

Ahora se explicará cómo asignar las probabilidades a los resultados del experimento. Los enfoques más usuales son el método clásico y el de frecuencia relativa.

El **método clásico** de asignación de probabilidades es apropiado cuando todos los resultados del experimento son igualmente probables. Si n resultados son posibles, una probabilidad de $1/n$ se asigna a cada resultado experimental. La probabilidad de un suceso A, es:

$$P(A) = \frac{\text{Casos favorables}}{\text{Casos posibles}}$$

Suponiendo el experimento de tirar una moneda y ver la cara que sale, el espacio muestral es:

$$S = \{Cara, Seca\}$$

Definiendo al suceso A, como que salga cara:

$$A = \{Cara\}$$

La probabilidad que salga cara es:

$$P(A) = \frac{1}{2} = 0,5$$

Es decir la probabilidad que sea cara es del 50%


El **método de frecuencia** relativa de asignación de probabilidades es apropiado cuando los datos están disponibles para estimar la proporción del tiempo en que ocurrirá el resultado si el experimento se repite un gran número de veces. Entonces la probabilidad de un suceso A, es:

$$P(A) = \lim_{n \rightarrow \infty} \frac{\text{Cantidad de veces que se repite A en } n}{n}$$

Tomando el caso anterior de calcular la probabilidad que sea cara debemos, tirar la moneda y contar la cantidad de veces que salió cara, por ejemplo si la tiramos 10 veces y salió cara 6 veces:

$$P(A) = \lim_{n \rightarrow \infty} \frac{\text{Cantidad de veces que se repite A en } n}{n} = \frac{6}{10} = 0,6$$

Mientras más veces hagamos el experimento más cerca del verdadero valor, lo ideal sería hasta el infinito, pero esto es humanamente imposible. El gráfico de abajo muestra la probabilidad estimada en el eje de ordenadas y en el eje de abscisas la cantidad de veces que se tiró la moneda. A medida que el número tiro aumenta la probabilidad estimada se acerca al verdadero valor de 0,5.



Variable Aleatoria Discreta y Continúa

Anteriormente se definió el concepto de experimento y los resultados experimentales correspondientes. Una variable aleatoria proporciona un medio para describir estos resultados con valores numéricos. Las variables aleatorias deben asumir valores numéricos. Una **variable aleatoria** es una descripción numérica de los resultados de un experimento. La variable aleatoria se anota con una letra mayúscula imprenta, lo más usual es usar X o Y. Cuando es un valor observado de la variable aleatoria se anota con letra imprenta minúscula, x o y, según corresponda.

En efecto, una variable aleatoria asocia un valor numérico con cada resultado experimental posible. El valor numérico particular de la variable aleatoria depende del resultado del experimento. Ésta se clasifica como discreta o continua en función de los valores numéricos

que asume.

Una variable aleatoria que puede asumir cualquier número finito de valores o una sucesión infinita de valores como 0, 1, 2, . . . se conoce como **variable aleatoria discreta**, es decir representa **conteos**.

Por otro lado, cuando una variable aleatoria asume cualquier valor numérico en un intervalo o conjunto de intervalos se llama **variable aleatoria continua**. En este caso la variable aleatoria representa **mediciones**.

La distribución de probabilidad de una variable aleatoria describe cómo se distribuyen las probabilidades entre los valores de la misma. Para una variable aleatoria discreta X , la distribución de probabilidad se define por medio de una función de probabilidad, denotada por $f_X(x)$. Esta función es denominada **función densidad de probabilidad**, y está definida como:

$$f_X(x) = P(X = x)$$

Cuando se habla de variables aleatorias tanto discreta o continua es común anotar la esperanza de la variable aleatoria X , como:

Si la variable aleatoria es discreta:

$$E(X) = \sum_{x_j \in X(S)} x_j f_X(x_j) = \mu$$

Si la variable aleatoria es continua:

$$E(X) = \int_{-\infty}^{+\infty} x f_X(x) dx = \mu$$

y la varianza como:

Si la variable aleatoria es discreta:

$$Var(X) = \sum_{x_j \in X(S)} (x_j - E(X))^2 f_X(x_j) = \sigma^2$$

Si la variable aleatoria es continua:

$$Var(X) = \int_{-\infty}^{+\infty} (x_j - E(X))^2 f_X(x) dx = \sigma^2$$

.

Modelos de distribución

Distribución de Bernoulli

Una variable aleatoria X tiene distribución de Bernoulli, si su función de densidad de probabilidad está dada por:

$$f_X(x) = p^x (1 - p)^{x-1} I_{\{0,1\}}(x)$$

donde:

- p es la probabilidad de éxito y debe cumplir $0 \leq p \leq 1$
- 0 representa “0” éxito y 1 representa “1” éxito

la esperanza es:

$$E(X) = p$$

y la varianza:

$$Var(X) = \sigma^2 = p(1 - p)$$

Distribución Binomial

Esta distribución probabilidad se aplica cuando tenés una cantidad finita de casos, por ejemplo exportamos 10 cajas de vinos malbec y queremos determinar la probabilidad de que 4 no sean vendidas, cuando la probabilidad de no vender una caja es del 0.30 o el 30%.

Una **variable aleatoria discreta** tiene **distribución binomial** cuando cumple las cuatro

propiedades siguientes.

1. El experimento consiste de una secuencia de n ensayos idénticos.
2. En cada ensayo hay dos resultados posibles. A uno de ellos se le llama éxito y al otro, fracaso.
3. La probabilidad de éxito, denotada por p , no cambia de un ensayo a otro. Por consiguiente, la probabilidad de fracaso, denotada por $1 - p$, tampoco cambia de un ensayo a otro.
4. Los ensayos son independientes.


La **función densidad o de probabilidad** está definida como:

$$f_X(x) = \frac{n!}{x!(n-x)!} p^x (1 - p)^{n-x}$$

Entonces para calcular la probabilidad de que cuatro cajas no sean vendidas de 10, es:

$$f_X(4) = \frac{10!}{4!(10-4)!} 0,3^4 (1 - 0,3)^{10-4} = 0,20$$

Si hacemos este mismo procedimiento para las 10 posibles alternativas, podemos hacer el gráfico de barra:



la esperanza es:

$$E(X) = np$$

Para el caso de las cajas de vino:

$$E(X) = 10 * 0,3 = 3$$

Significa que en 10 cajas de vino en promedio no se venden

y la varianza:

$$Var(X) = \sigma^2 = np(1 - p)$$

Para el caso de las cajas de vino:

$$Var(X) = \sigma^2 = 10 * 0,3(1 - 0,3) = 2,1$$

y calculando la desviación estándar:

$$\sigma = \sqrt{Var(X)} = \sqrt{2,1} = 1,44$$

Se interpreta que en promedio no se vender 1,44 con respecto a la media

Distribución Normal

La distribución de probabilidad más importante para describir una **variable aleatoria continua** es la **distribución de probabilidad normal**. Gran parte de los modelos básicos de estadística parten de esta distribución: Estimación por intervalo, inferencia, modelo lineal simple, múltiple, polinómico, factores y series de tiempo como se verá más adelante.

No solo la estadística usa esta distribución, en **Machine Learning** existen algoritmos de clasificación que también se basan en esta distribución: Modelo logístico, Clasificador

Bayesiano, LDA, QDA, entre otros. También algunos algoritmos de regresión de machine learning usan esta distribución: tal como Lasso y Ridge.


La función de distribución de probabilidad o función densidad está expresada como:

$$f_X(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2\sigma^2}(x-\mu)^2}$$

donde:

- $E(X) = \mu$ es la media
- $\sqrt{Var(x)} = \sigma$ desviación estándar
- $\pi=3,14150$
- $e=2,71828$

Supongamos que en una pyme tienen una máquina para el llenado de envases de productos químicos. Según las especificaciones del fabricante esta máquina llena en promedio $\mu = 500$ ml (mililitros), con una desviación de $\sigma = 10$ ml. La gráfica de la función densidad anterior es:



Supongamos que se quiere calcular la probabilidad de que esta máquina llene una bollera con menos de 490 ml . Desde un punto de vista gráfico, la probabilidad es el área azul debajo de la curva, ya que se trata de una variable aleatoria continua.

$$P(X < 490) = 0,16$$

Esto significa que el 16% de las botellas van a ser llenadas con menos de 490 ml. Esta probabilidad tiene que ser calculada mediante tablas o algún programa ya que no se puede integrar la función densidad de esta variable.

Existen varias características de la distribución normal, las más importantes son:

1. La familia completa de distribuciones normales se diferencia por medio de dos parámetros: **la media μ y la desviación estándar σ** .
2. El punto más alto de una curva normal se encuentra sobre la media, el cual coincide con la mediana y la moda de la distribución.

3. La media de una distribución normal puede tener cualquier valor numérico: negativo, cero o positivo
4. La distribución normal es simétrica: la forma de la curva normal a la izquierda de la media es una imagen de espejo de la forma de la curva a la derecha de la media
5. La desviación estándar determina qué tan plana y ancha es la curva normal.
6. Las probabilidades para la variable aleatoria normal están representadas por las **áreas bajo la curva normal**. Es decir siempre se cumple que $P(X=x)=0$. Esto es válido para cualquier variable aleatoria continúa

Estadística descriptiva

Generalmente cuando se inicia el estudio de una variable, lo primero que se hace es describir los datos que se obtienen mediante el muestreo. Es como sacar una “fotografía” de una determinada variable, por ejemplo, cuántas cantidades de unidades de paquetes de galletas hay en stock o el gasto promedio de un cliente por día.

La idea general, no es hacer ningún tipo de inferencia o predicción, si no determinar cuál es la situación actual de la variable y saber donde se está parado. Esto nos permite como primera aproximación, si se ha cumplido con el plan de negocio definido o para determinar cómo se está comportando las ventas, los retrasos en los pedidos, las roturas, las licencias por enfermedad, etc

Visualización y exploración de datos

Tipos de datos

En los módulos anteriores se vio el concepto de datos y las formas de administrar estos. Desde un punto de vista estadístico los **datos** son los hechos y las cifras obtenidas, analizados y resumidos para su presentación e interpretación. Cuando se habla de **Población** se refiere al universo o totalidad de elementos sobre los que se investiga, por ejemplo: el total de clientes, especificaciones del producto, demanda del servicio, etc. Por otro lado, la **Muestra** es una parte o subconjunto de elementos que se seleccionan previamente de una población para realizar un estudio.

Datos categóricos (o cualitativos) y cuantitativos

Los datos se clasifican como categóricos o cuantitativos. Los que se agrupan por categorías específicas se conocen como **datos categóricos**. Este tipo de datos utiliza una escala de medición que puede ser nominal (sexo, nacionalidad) u ordinal (grado de educación, clasificación de riesgo). Los que utilizan valores numéricos para indicar cuánto o cuántos se conocen como **datos cuantitativos**; éstos se obtienen usando una escala de medición: Cantidad de cajas de vino vendidas, tiempo de cocción, costo por km recorrido, tasa de interés, resultado neto, etc.

Dentro de los datos cuantitativos existen dos tipos. Los **datos discretos** son aquellos que representan conteos (números enteros: 2,3,90,...), por ejemplo: cantidad de suscripciones por mes, cantidad de faltantes en el camión, cantidad de computadoras vendidas, etc . Por otro lado, los **datos continuos** los que representan mediciones (Números con “,”: 1,89 , 3,456,...), por ejemplo, cambio porcentual en las ventas, activo, tiempo de despacho, valor del dólar, etc.

Datos de corte transversal y de series de tiempo

Para efectos del análisis estadístico es importante distinguir entre datos de corte transversal y datos de series de tiempo. Los **datos de corte transversal** son obtenidos en el mismo momento, o aproximadamente al mismo tiempo. Los **datos de series de tiempo** son obtenidos a lo largo de varios periodos.

Medidas de estadística descriptiva

Distribución de frecuencia

Una **distribución de frecuencia** es un resumen tabular de datos que muestran el número (frecuencia) de elementos en cada una de varias clases que no se superponen. Cuando hablamos de frecuencia nos referimos a dos conceptos distintos:

Frecuencia absoluta: es la cantidad de veces que sale cada categoría en la muestra:

$$f_a(x) = \text{cantidad de veces que salió la categoría } x \text{ en } n$$

Frecuencia relativa, que es el porcentaje de veces que sale cada categoría en la muestra:

$$f_r(x) = \frac{\text{cantidad de veces que salió la categoría } x \text{ en } n}{n}$$

Datos discretos

Para armar una distribución de frecuencia cuando los datos son discretos, la categoría “x” va a estar representada por un número discreto. La forma de graficar es mediante un gráfico de barra.

Un **gráfico de barra** es una representación gráfica de una variable en forma de barras, donde la altura de cada barra es proporcional a la frecuencia relativa de los valores representados.


Supongamos que se quiere estudiar la cantidad de cajas de mercadería que se envían a los clientes por día, para ello se toma la siguiente muestra de 20 días:

17, 20, 21, 18, 20, 20, 20, 18, 19, 19, 20, 20, 19, 21, 20, 18, 20, 20, 19, 18

La distribución de frecuencias es:

(x)	$f_a(x)$	$f_r(x)$
17	1	0,05
18	4	0,2
19	4	0,2
20	9	0,45
21	2	0,1

Esto se interpreta de la siguiente forma: para $x=17$, es decir cuando se envió 17 cajas, solo registró un día de los 20, que se envió es cantidad y representa el 5% de las veces. Notar que al 0,05 se multiplicó por 100% para transformarse en porcentaje. Esta información es la que se puede ver en el gráfico de barras:



[Ver ejercicio N°1](#)

Datos continuos

Por otro lado, para armar una distribución de frecuencia cuando los datos son continuos, la categoría x va a estar representada por un intervalo. La cantidad de intervalos se puede estimar mediante la [ecuación de Sturgis](#) o en forma aleatoria. La forma de graficar es mediante un histograma.

Un **histograma** es una representación gráfica de una variable en forma de barras, donde la superficie de cada barra es proporcional a la frecuencia de los valores representados.

La siguiente muestra, corresponde a datos continuos, en donde se midió el rendimiento patrimonial de una pyme de Mendoza, en porcentaje, en los últimos 13 años:

6.40, 5.21, 4.66, 5.24, 6.96, 5.53, 8.23, 6.80, 5.78, 6.00, 5.41, 6.23, 7.23

La distribución de frecuencias es:

Clase (x)	$f_a(x)$	$f_r(x)$	$\hat{f}_x(x)$
[4,5)	1	0,076	0,076
[5,6)	6	0,461	0,461
[6,7)	4	0,307	0,307
[7,8)	1	0,076	0,076
[8,9]	1	0,76	0,076


Si tomamos la tercera fila vemos que solo 6 años, la pyme tuvo rendimientos entre el 5% y 6% , esto presenta el 46,1% de las veces. Como se trata de datos continuos, el gráfico que se debe realizar, es el histograma. La gran diferencia con el gráfico de barras es que la frecuencia relativa está representada por la superficie y no por la altura. Entonces, teniendo en cuenta que la superficie es base por altura, podemos definir:

$$f_r(x) = \text{ancho de clase (base)} * \hat{f}_x(x) (\text{altura})$$

para el caso anterior la base es 1, ya que la distancia entre [5,4) es 1 y esto es igual para todas las clases, entonces podemos calcular la altura dado por $\hat{f}_x(x)$:

$$\hat{f}_x(x) = \frac{f_r(x)}{\text{ancho de clase}}$$

Para la primer clase: $\hat{f}_x(x) = 0,076/1 = 0,076$. Haciendo este cálculo para todas las clases, podemos graficar el histograma:



[Ver ejercicio N°2](#)

Media muestral

La **media muestral**, o valor medio, es quizá la medida de ubicación más importante para una variable, pues proporciona una medida de la ubicación central de los datos. La media muestral se denota por $\bar{x}$:

$$\bar{x} = \frac{\sum_{i=1}^n x_i}{n}$$

En la fórmula anterior, el numerador es la suma de los valores de las **n observaciones**. Es decir:

$$\sum_{i=1}^n x_i = x_1 + x_2 + \dots + x_n$$

Siguiendo el caso de del rendimiento patrimonial, la media muestral es del 6,12, esto significa que en promedio de los últimos 13 años el promedio de rendimientos es del 6,12%, la forma de calcular es:

$$\bar{x} = \frac{6.40 + 5.21 + 4.66 + 5.24 + 6.96 + 5.53 + 8.23 + 6.80 + 5.78 + 6.00 + 5.41 + 6.23 + 7.23}{13} = 6,12$$

Mediana muestral

La **mediana muestral** es otra medida de ubicación central; es el valor del medio cuando los datos están acomodados en orden ascendente (del valor menor al valor mayor). Con un número impar de observaciones, la mediana es el valor del medio. Con un número par, no hay valor del medio. En este caso se sigue la convención y la mediana se define como el promedio de los valores de las dos observaciones del medio. Por conveniencia, la definición de la mediana se replantea como sigue:

si es par:

$$md = \frac{x_{(\frac{n}{2})} + x_{(\frac{n}{2}+1)}}{2}$$

si es impar:

$$md = x_{(\frac{n+1}{2})}$$

donde $x_{(i)}$ es el valor observado en la posición i.

Para la muestra del rendimiento patrimonial, la cantidad de datos son 13, si los ordenamos nos queda:

$x_{(1)}$	$x_{(2)}$	$x_{(3)}$	$x_{(4)}$	$x_{(5)}$	$x_{(6)}$	$x_{(7)}$	$x_{(8)}$	$x_{(9)}$	$x_{(10)}$	$x_{(11)}$	$x_{(12)}$	$x_{(13)}$
4.66	5.21	5.24	5.41	5.53	5.78	6	6.23	6.4	6.8	6.96	7.23	8.23

Entonces para calcular la mediana:

6

Esto se interpreta como de la siguiente forma, como mínimo el 50% de las veces el rendimiento patrimonial fue como máximo de un 6% anual.

Moda muestral

Para datos discretos la **moda muestral** es el valor con mayor frecuencia relativa o absoluto.

Para datos continuos la **moda muestral simple** la podemos definir:

$$moda = \frac{L_i + L_s}{2}$$

donde L_i es el límite inferior de la clase con mayor frecuencia y L_s es el límite superior de la clase con mayor frecuencia.

En el caso que todos los valores tengan la misma frecuencia relativa o absoluta, **no hay moda** y si se tiene valores con frecuencia repetidas, entonces la distribución es **multimodal**.

Retomando la distribución de frecuencia del rendimiento patrimonial, podemos observar que la segunda clase es la que tiene mayor frecuencia, esto es: una frecuencia de 0,461 y corresponde al intervalo [5,6), entonces el límite inferior es 5 y el límite superior es 6, para estimar la moda simple:

$$moda = \frac{L_i + L_s}{2} = \frac{5+6}{2} = 5,5$$

Cuantil muestral

El **Cuantil muestral** es un valor tal que por lo menos “ q ” por ciento de las observaciones es menor o igual que este valor, y por lo menos $(1 - q)$ por ciento de las observaciones es mayor. Los datos se pueden dividir en k partes iguales, por lo tanto existen $k-1$ cuantiles. Para su cálculo los valores deben estar ordenados de menor a mayor:

$$\hat{x}_q = x_{(q(n+1))}$$

si la expresión $q(n + 1)$ no es un número entero se redondea al entero superior. El sombrero sobre la $\hat{x}_q$, indica que es el p-ésimo cuantil basado en la muestra. Si los datos se dividen en 4 partes iguales, se llaman cuartiles. Existen 3 cuartiles: $Q_1 = \hat{x}_{0,25}$, $Q_2 = \hat{x}_{0,50}$ (En este caso es la mediana) y $Q_3 = \hat{x}_{0,75}$

Si los datos se dividen en 10 partes iguales, se llaman deciles. Existen 9 deciles

Si los datos se dividen en 100 partes iguales, se llaman percentiles. Existen 99 percentiles

Para calcular el primer cuartil en el caso del rendimiento patrimonial:


$$Q_1 = \hat{x}_{0,25} = x_{(0,25(13+1))} = x_{(3.5)} = x_{(4)} = 5,41$$

Siguiendo el ejemplo, esto se interpreta: como mínimo el 25% de la veces el rendimiento patrimonial fué como máximo un 5,41%

Otra representación gráfica de datos continuos es el gráfico de **caja y bigotes**. En este gráfico se marca el primer, segundo y tercer cuartil. También los máximos y mínimos. Si un valor queda por fuera del rango intercuartil por 1,5, se llaman **valores atípicos** (outlier)

Es gráfico es útil para comprar los cuantiles entre sí y poder ver las diferencias relativa entre ellas y determinar la simetría de los datos en forma gráfica, es decir si existe la misma

distancia entre Q_2 y Q_1 y Q_2 y Q_3 . También es útil, determinar la existencia de datos atípicos, ya que estos podrían errores de medición o nos da pistas sobre la distribución de probabilidad de la variable a estudiar.




Para estimar el bigote se calcula el RIC (rango intercuartil) que es la diferencia entre Q_3 y Q_1 , entonces el bigote superior se calcula:

$$Bigote\ superior = Q_3 + 1,5 (Q_3 - Q_1) = Q_3 + 1,5 RIC$$

$$Bigote\ inferior = Q_1 - 1,5 (Q_3 - Q_1) = Q_1 - 1,5 RIC$$

Para el caso del rendimiento patrimonial, el diagrama de cajas y bigotes nos queda:



En este gráfico podemos observar que no hay datos atípicos y hay algo de simetría entre Q_2 y Q_1 y Q_2 y Q_3 .

Varianza muestral

La **varianza muestral** es la medida de variabilidad más utilizada. Se basa en la diferencia entre el valor de cada observación (x_i) y la media. Si se desea calcular la varianza muestral, las desviaciones respecto de la media se elevan al cuadrado, para eliminar el efecto de las puntuaciones negativas.

Aunque una explicación detallada está más allá del alcance de este curso, puede mostrarse que si la suma de las desviaciones respecto de la media al cuadrado se divide entre $n-1$, y no entre n . Por esta razón, la **varianza muestral**, denotada por s^2 , se define como sigue.

$$s^2 = \frac{\sum (x_i - \bar{x})^2}{n-1}$$

Para estimar la varianza muestral, del ejemplo del rendimiento patrimonial:

$$s^2 = \frac{\sum (x_i - \bar{x})^2}{n-1} = \frac{(6,60-6,12)^2 + (5,21-6,12)^2 + \dots + (6,21-6,12)^2 + (x_i-7,23)^2}{13-1} = 0,97$$

Desviación estándar muestral

La **desviación estándar** se define como la raíz cuadrada positiva de la varianza muestral:

$$s = \sqrt{s^2}$$

Para el caso del rendimiento patrimonial, podemos calcular la desviación estándar muestral:

$$s = \sqrt{s^2} = \sqrt{0,97} = 0,98$$

Esto se interpreta de la siguiente forma, el promedio de variación del rendimiento patrimonial con respecto al media muestral es de 0,98%

Coefficiente de correlación muestral

Hasta ahora hemos examinado los métodos numéricos que resumen los datos de una variable a la vez. Por ejemplo, un gerente o quien toma decisiones se interesa con frecuencia en la relación entre dos variables. En esta sección se presentan la covarianza y la correlación como medidas descriptivas de la relación entre dos variables. La **covarianza muestral** es una medida descriptiva de la asociación lineal entre dos variables X e Y.

Covarianza muestral

$$s_{X,Y} = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{n-1}$$

La covarianza está afectada por el nivel de escala de las variables aleatorias X e Y. Para eliminar este efecto dividimos a la covarianza por las desviaciones estándares. El **coeficiente de correlación muestral** del producto-momento de Pearson se define como se indica a continuación.

$$r_{X,Y} = \frac{s_{X,Y}}{s_X s_Y}$$

El coeficiente de correlación toma valores entre -1 y 1. Cuando el valor se aproxima a 1 significa que hay una relación positiva entre X e Y. Por otro lado, si se acerca a -1, hay una relación negativa. Por último si se aproxima a 0, significa que no hay relación o correlación entre X e Y.

[Ver Ejercicio N°3](#)

Muestreo y estimación

Cómo seleccionar una muestra (finita-infinita)

En la sección anterior se presentaron las siguientes definiciones:

- Un **elemento** es la entrada en la que se recolectan los datos
- Una **población** es el conjunto de todos los elementos de interés
- Una **muestra** es un subconjunto de la población

La razón por la que se selecciona una muestra consiste en recabar datos para realizar una **inferencia** y responder una pregunta de investigación acerca de una población. Una **muestra aleatoria simple de tamaño n de una población finita de tamaño N** es una muestra seleccionada de tal manera que cada posible muestra de tamaño n tenga la misma probabilidad de ser seleccionada.

Por otro lado cuando la población tiene infinitos elementos, decimos que una **muestra aleatoria de tamaño n de una población infinita** es seleccionada de manera tal que se satisfagan las condiciones siguientes:

- Cada elemento elegido proviene de la misma población.
- Cada elemento es seleccionado de manera independiente.

Distribución de muestreo

Como $\bar{x}$ es una función de una muestra aleatoria, entonces $\bar{x}$ también es una variable aleatoria, por lo tanto tiene función densidad, media o esperanza matemática y desviación

estándar. Entonces cuando nos referimos a la variable aleatoria media muestral lo anotamos como $\bar{X}$ y al valor observado como $\bar{x}$.

Se puede demostrar que la esperanza o media poblacional para la variable aleatoria media muestral $\bar{X}$ es:

$$E(\bar{X}) = \mu$$

La desviación estándar va a depender si la muestra es de una población finita o infinita:

Población finita

Una población es finita cuando, se conocen o se puede medir todos los elementos de la población, por ejemplo, salario de una empresa de 1000 empleados, y se toma una muestra de 100, entonces $N=1000$ y $n=100$.

$$\sigma_{\bar{X}} = \sqrt{\frac{N-n}{N-1} \frac{\sigma_X}{n}}$$

Población infinita

Una población se considera infinita cuando la población es tan grande que no se puede acceder o medir todos los elementos o cuando estos son infinitos, por ejemplo el salario de los argentinos.

$$\sigma_{\bar{X}} = \frac{\sigma_X}{n}$$

Tipos de muestreo

Los resultados anteriores respecto del valor esperado y la desviación estándar en la distribución de muestreo de $\bar{X}$ son aplicables a cualquier población. El paso final para identificar las características de la distribución de muestreo de $\bar{X}$ consiste en determinar la forma de la distribución de muestreo. Se considerarán dos casos: 1) La población tiene distribución normal, y 2) La población no tiene distribución normal.

La población tiene distribución normal. En muchas situaciones es razonable suponer que la población de la que se selecciona la muestra aleatoria simple tiene distribución normal o casi normal. Cuando esto ocurre, la distribución de muestreo de $\bar{X}$ está distribuida normalmente cualquiera que sea el tamaño de la muestra .

La población no tiene distribución normal. Cuando la población de la que se tomó la muestra aleatoria simple no tiene distribución normal, el teorema del límite central ayuda a determinar la forma de la distribución de muestreo de $\bar{X}$. El enunciado de este teorema aplicado a la distribución de muestreo de $\bar{X}$ dice lo siguiente.

Teorema del límite central

Cuando se seleccionan muestras aleatorias simples de tamaño n de una población, la distribución de muestreo de la media muestral $\bar{X}$ puede aproximarse mediante una distribución normal a medida que el tamaño de la muestra se hace grande.

Desde un punto de vista empírico, se puede considerar que cuando n sea mayor o igual a 30, entonces la media muestral $\bar{X}$ Tiene distribución normal.

Estimación puntual

En la sección anterior se han explicado los estadísticos muestrales $\bar{x}$ y s^2 . Los valores observados, en base a la muestra, $\bar{x}$ y s^2 son **estimadores puntuales** de los parámetros μ y σ^2 poblacionales en el caso de ser desconocidos.

Los estimadores puntuales son derivados de métodos como método de los momentos o métodos de máxima verosimilitud y deben cumplir con determinadas propiedades, no obstante estos métodos están fuera del alcance de este curso.

Si retomamos el ejemplo del rendimiento patrimonial, sabemos que es una variable aleatoria, entonces esta tiene su distribución de probabilidad, su media o esperanza matemática y su varianza. El tema es que no conocemos ninguno de ellos:

1- Para estimar su distribución de probabilidad, usamos los datos del arreglo o tabla de frecuencias visto en la primer parte, tomando la última columna, ya que la superficie marca la probabilidad, nos queda la distribución de probabilidad empírica, que se anota:

$$\hat{f}_x(x) = 0,076I_{[4,5)}(x) + 0,461I_{[5,6)}(x) + 0,307I_{[6,7)}(x) + 0,076I_{[7,8)}(x) + 0,076I_{[8,9)}(x)$$

Cuando se usa la indicación del sombrero, $\hat{}$ es para indicar que es una estimación basada en una muestra. Por otro lado, I significa que “indicativo” de la variable, (x) y el subíndice marca el intervalo de clase.

2- Para estimar la media poblacional μ (como es la poblacional no lleva sombrero), usamos el estimador puntual:

$$\bar{x} = \hat{\mu} = \frac{\sum_{i=1}^n x_i}{n} = 6,12$$

3-Para estimar la varianza poblacional, usamos su respectivo estimador puntual:

$$s^2 = \hat{\sigma}^2 = \frac{\sum (x_i - \bar{x})^2}{n-1} = \frac{(6,60-6,12)^2 + (5,21-6,12)^2 + \dots + (6,21-6,12)^2 + (x_i-7,23)^2}{13-1} = 0,97$$

Por una propiedad llamada invarianza, el estimador puntual de la desviación poblacional es:

$$s = \hat{\sigma} = \sqrt{s^2} = \sqrt{0,97} = 0,98$$

Estimación por intervalo

Los estimadores puntuales nos dan un estimado de los verdaderos parámetros poblacionales, no obstante en algunos casos es necesario establecer un límite máximo y mínimo para el parámetro poblacional, ya que no se puede esperar que dicho estadístico muestral suministre el valor exacto del parámetro poblacional, se suele calcular una **estimación por intervalo** al sumar y restar a la estimación puntual un cantidad llamada margen de error. La forma general de una estimación por intervalo es:

$$\text{Estimación puntual} + / - \text{margen de error}$$

Para la media poblacional con con desviación conocida

$$\left(\bar{x} - z_{\frac{1+\gamma}{2}} \frac{\sigma}{\sqrt{n}}; \bar{x} + z_{\frac{1-\gamma}{2}} \frac{\sigma}{\sqrt{n}} \right)$$

Donde:

- $\bar{x}$ valor observado de la media muestral o estimación puntual
- γ nivel de confianza, como es una probabilidad este es entre 1 y 0
- $z_{\frac{1+\gamma}{2}}$ y $z_{\frac{1-\gamma}{2}}$ cuantiles de una distribución normal con media 0 y desviación estándar 1.
- σ desviación estándar poblacional

- n tamaño de la muestra (población infinita)


La forma de obtener el **intervalo de confianza**, se llama método de la cantidad pivotal. Este método parte de la idea de que hay que calcular los límites máximo y mínimo en función de una probabilidad en donde pertenece el parámetro poblacional, por eso se requiere establecer una confianza o probabilidad denominada γ (Por eso se denomina intervalo de confianza). Este valor comúnmente es del 0,95 o 95%.

El estimador puntual para la media poblacional del rendimiento patrimonial fue de 6,12, pero no nos dice un valor máximo o mínimo. Supongamos que la varianza poblacional es de $\sigma = 1$ entonces para construir el intervalo de confianza del 95%:


$$\left(\bar{x} - z_{\frac{1+\gamma}{2}} \frac{\sigma}{\sqrt{n}}; \bar{x} + z_{\frac{1-\gamma}{2}} \frac{\sigma}{\sqrt{n}} \right)$$

donde, z son cuantiles de una distribución normal con media poblacional $\mu = 0$ y desviación estándar poblacional $\sigma = 1$. Esta distribución se denomina distribución normal estándar:

$$z_{\frac{1-0,95}{2}} = z_{0,025} = -1,96$$



$$Z_{\frac{1+0,95}{2}} = Z_{0,975} = 1,96$$



Reemplazando:

$$(6,12 - 1,96 \frac{1}{\sqrt{13}}; 6,12 + \frac{1}{\sqrt{13}})$$

Que es igual a:

$$(5,57 ; 6,66)$$

Esto se interpreta que hay una **confianza** del 95% que la media poblacional del rendimiento patrimonial se encuentre entre 5,57% y el 6,66%. Notar que se usa la palabra confianza y no probabilidad ya que la probabilidad está definida para un suceso o variable aleatoria y no para una observación.

[Ver ejercicio N°8](#)

Para la media poblacional con con desviación desconocida

El caso anterior corresponde a un caso teórico, ya que lo normal es que tampoco se conozca el valor poblacional de σ . Cuando no se conoce se reemplaza σ por su valor estimado s

$$(\bar{x} - t_{\frac{1+\gamma}{2}} \frac{s}{\sqrt{n}}; \bar{x} - t_{\frac{1-\gamma}{2}} \frac{s}{\sqrt{n}})$$

Donde:

- $\bar{x}$ valor observado de la media muestral o estimación puntual
- γ nivel de confianza, como es una probabilidad este es entre 1 y 0
- $t_{\frac{1+\gamma}{2}}$ y $t_{\frac{1-\gamma}{2}}$ cuantiles de una distribución t-student con n-1 grados de libertad
- s valor observado de desviación estándar muestral
- n tamaño de la muestra (población infinita)

Supongamos que no se conoce el valor de σ , entonces se tiene que usar el valor estimado de $s = 0,98$. Los cuantiles t , corresponden a la distribución denominada t-student:

$$t_{\frac{1+0,95}{2}, n-1} = t_{0,975, 12} = 2,17$$

$$t_{\frac{1-0,95}{2}, n-1} = t_{0,025, 12} = -2,17$$

Reemplazando:

$$(6,12 - 2,17 \frac{0,98}{\sqrt{13}}; 6,12 + 2,17 \frac{0,98}{\sqrt{13}})$$

Que es igual a:

$$(5,53 ; 6,70)$$

La interpretación es igual que la anterior. Notar que el intervalo es más grande en este caso ya una pérdida de precisión por no saber el valor exacto de la desviación estándar poblacional.

[Ver ejercicio N°9](#)

Inferencia estadística

En esta sección se continúa con el estudio de la inferencia estadística mostrando cómo usar la prueba de hipótesis para determinar si una afirmación acerca del valor de un parámetro

poblacional debe o no ser rechazada.

En las pruebas de hipótesis se empieza por hacer un supuesto tentativo acerca del parámetro poblacional. A este supuesto tentativo se le llama **hipótesis nula**, y se denota por H_0 . Después se define otra hipótesis, llamada **hipótesis alternativa**, que contradice lo que establece la hipótesis nula y se denota como H_1

Prueba de hipótesis con σ poblacional conocida

Cola Superior

$$H_0: \mu \leq \mu_0 \quad vs \quad H_1: \mu > \mu_0$$

Test: Se rechaza H_0 si y solo si $p - valor < \alpha$

donde:

$$p - valor = P(T_0 > \bar{x}_0)$$

$T_0 = \frac{\bar{X} - \mu_0}{\frac{\sigma}{\sqrt{n}}}$, es un estadístico que tiene distribución Normal con media 0 y desviación

estándar de 1. Para los casos en que la población sea de origen normal o que la muestra sea mayor a 30. Notar que el subíndice 0, hace referencia a que se está suponiendo hipótesis nula verdadera.

El valor de α , es definido por el investigador comúnmente este valor es de 0,05 o el 5%. Por otra lado a α se lo conoce error **Tipo 1**, ya que como no se conoce el verdadero valor poblacional y la prueba de se basa en una muestra que es aleatoria, podemos cometer un error al rechazar H_0 cuando esté es verdadero. Por otra lado el error **Tipo 2**, es cuando no rechazamos H_0 y esta es Falsa.

Supongamos que el gerente de la pyme quiere determinar si el rendimiento patrimonial se puede considerar **mayor** a 7%. Nuevamente supongamos que la desviación poblacional es de $\sigma = 1$ y usando un $\gamma = 0,05$. Entonces las hipótesis son:


$$H_0: \mu \leq 7 \text{ vs } H_1: \mu > 7$$

Entonces para calcular $\bar{x}_0$:

$$t_0 = \frac{\bar{x} - \mu_0}{\frac{\sigma}{\sqrt{n}}} = \frac{6,12 - 7}{\frac{1}{\sqrt{13}}} = -3,13$$

Finalmente el valor p:

$$p - \text{valor} = P(T_0 > \bar{x}_0) = P(T_0 > -3,13) = 0,99$$



Este cálculo de probabilidad se tiene que hacer mediante un software, ya que no se puede integrar la función de la distribución normal.

Como $p - valor = 0,99 > \gamma = 0,05$ entonces no rechazamos H_0 por lo tanto no hay evidencia para considerar a la media poblacional del rendimiento patrimonial mayor al 7%.

Cola Inferior

$$H_0: \mu \geq \mu_0 \quad vs \quad H_1: \mu < \mu_0$$

Test: Se rechaza H_0 si y solo si $p - valor < \alpha$

donde:

$$p - \text{valor} = P(T_0 < \bar{x}_0)$$

$T_0 = \frac{\bar{X} - \mu_0}{\frac{\sigma}{\sqrt{n}}}$, es un estadístico que tiene distribución Normal con media 0 y desviación estándar de 1, en el caso de que la población de origen sea normal o que la muestra sea mayor a 30.

Supongamos ahora que el gerente de la pyme quiere determinar si el rendimiento patrimonial se puede considerar **menor** al 7%. Nuevamente supongamos que la que la desviación poblacional es de $\sigma = 1$ y usando un $\alpha = 0,05$. Entonces las hipótesis son:


$$H_0: \mu \geq 7 \text{ vs } H_1: \mu < 7$$

Entonces para calcular $\bar{x}_0$:

$$t_0 = \frac{\bar{x} - \mu_0}{\frac{\sigma}{\sqrt{n}}} = \frac{6,12 - 7}{\frac{1}{\sqrt{13}}} = -3,13$$

Finalmente el valor p:

$$p - \text{valor} = P(T_0 < \bar{x}_0) = P(T_0 < -3,13) = 0,01$$



Como $p - valor = 0,01 < \gamma = 0,05$ entonces rechazamos H_0 por lo tanto no hay evidencia para considerar que la media poblacional del rendimiento patrimonial es menor al 7%.

Ambas colas

$$H_0: \mu = \mu_0 \quad vs \quad H_1: \mu \neq \mu_0$$

Test: Se rechaza H_0 si y solo si $p - valor < \alpha$

donde:

$$p - valor = 2 * P(T_0 > |\bar{x}_0|)$$

$T_0 = \frac{\bar{X} - \mu_0}{\frac{\sigma}{\sqrt{n}}}$ es un estadístico que tiene distribución Normal con media 0 y desviación estándar de 1, en el caso de que la población de origen sea normal o que la muestra sea mayor a 30.

Finalmente supongamos que el gerente de la pyme quiere determinar si el rendimiento patrimonial se puede considerar **igual** al 7%. Nuevamente supongamos que la desviación poblacional es de $\sigma = 1$ y usando un $\gamma = 0,05$. Entonces las hipótesis son:

$$H_0: \mu = 7 \text{ vs } H_1: \mu \neq 7$$

Entonces para calcular $\bar{x}_0$:

$$t_0 = \frac{\bar{x} - \mu_0}{\frac{\sigma}{\sqrt{n}}} = \frac{6,12 - 7}{\frac{1}{\sqrt{13}}} = -3,13$$

Finalmente el valor p:

$$p - \text{valor} = 2 * P(T_0 > |\bar{x}_0|) = 2 * P(T_0 > |-3,13|) = 2 * P(T_0 > 3,13) = 0,02$$

Como $p - \text{valor} = 0,02 < \gamma = 0,05$ entonces rechazamos H_0 por lo tanto no hay evidencia para considerar que la media poblacional del rendimiento patrimonial es distinto al 7%.

[Ver ejercicio N°10](#)

Prueba de hipótesis con σ poblacional desconocida

Cuando no se conoce la desviación estándar poblacional, el procedimiento es similar para cola

superior, cola inferior o ambas colas. La diferencia en que cambia la distribución de probabilidad del estadístico T_0 :


$T_0 = \frac{\bar{X} - \mu_0}{\frac{s}{\sqrt{n}}}$, es un estadístico que tiene distribución t-student con n-1 grados de libertad, en el caso de que la población de origen sea normal.

[Ver ejercicio N°11](#)

Indicadores y visualizaciones

Este proceso se aplica para poder extraer conocimiento de los datos con los que se cuenta.

Imagen N° 01 - Proceso de extracción de conocimiento



Título 2

A menudo el cliente tiene muchos objetivos que compiten entre sí y esos objetivos deben equilibrarse adecuadamente para que no se anulen entre ellos. Un ejemplo de lo que podría otorgar un equilibrio, es el análisis de los recursos disponibles con los que cuenta la empresa.

Título 3

El primer objetivo del científico de datos es el de comprender a fondo desde una perspectiva comercial, económica o de negocios, lo que el cliente realmente quiere y lo que podría lograr.

A menudo el cliente tiene muchos objetivos que compiten entre sí y esos objetivos deben equilibrarse adecuadamente para que no se anulen entre ellos. Un ejemplo de lo que podría otorgar un equilibrio, es el análisis de los recursos disponibles con los que cuenta la empresa.